

DAFTAR ISI

PRAKATA	iv
DAFTAR ISI	v
DAFTAR TABEL	vi
DAFTAR GAMBAR	vi
I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.3 Tujuan	4
1.4 Manfaat	4
II TINJAUAN PUSTAKA	5
2.1 Analisis Sentimen	5
2.2 <i>Natural Language Processing</i> (NLP)	5
2.3 <i>Long Short-Term Memory</i> (LSTM)	6
2.4 BERT dan IndoBERTweet	8
2.5 <i>Low-Rank Adaptation</i> (LoRA)	9
2.6 Data Tidak Seimbang	10
2.7 Evaluasi Kinerja Model Klasifikasi	10
III METODE	13
3.1 Data	13
3.2 Prosedur Analisis Data	14
DAFTAR PUSTAKA	17

DAFTAR TABEL

1	<i>Confusion Matrix</i> Klasifikasi Biner	11
2	<i>Confusion Matrix</i> Klasifikasi Multikelas	11
3	Parameter dan Nilai <i>Scraping</i> Data	13

DAFTAR GAMBAR

1	Sistem Analisis Sentimen	5
2	Arsitektur RNN	6
3	Arsitektur LSTM	7
4	Arsitektur BERT	8
5	Alur Kerja Penyempurnaan LoRA	10
6	Diagram Alir Penelitian	16

I PENDAHULUAN

1.1 Latar Belakang

Analisis sentimen merupakan teknik pengolahan data tekstual yang memanfaatkan pendekatan *Natural Language Processing* (NLP) dan *Machine Learning* (ML) untuk mengidentifikasi serta mengevaluasi opini, emosi, atau sikap yang terkandung dalam suatu teks secara otomatis. Umumnya, hasil analisis ini diklasifikasikan ke dalam kategori sentimen positif, negatif, dan netral. Analisis sentimen termasuk dalam bidang pemrosesan bahasa alami yang terus berkembang seiring dengan meningkatnya interaksi antara manusia dan komputer, khususnya dalam pemanfaatan data tekstual dari media sosial. Pendekatan ini bertujuan untuk mengekstraksi informasi serta menginterpretasikan emosi atau kecenderungan sikap yang diekspresikan pengguna melalui teks. Proses analisis sentimen melibatkan identifikasi kata, frasa, maupun pola bahasa yang merepresentasikan sentimen tertentu sehingga memungkinkan ekstraksi karakteristik dari data tekstual, baik yang bersifat terstruktur maupun tidak terstruktur, guna memperoleh gambaran mengenai pandangan, pendapat, dan perasaan pengguna (Prakash dan Aloysius 2021).

Seiring dengan meningkatnya penggunaan internet, masyarakat semakin aktif mengekspresikan opini dan pandangannya secara terbuka melalui berbagai platform media sosial. Fenomena ini menyebabkan volume data teks yang mengandung sentimen publik terus meningkat dan menjadi sumber informasi yang bernilai untuk dianalisis (Cen *et al.* 2020). Platform media sosial berbasis teks memiliki peran penting dalam kajian analisis sentimen, karena opini, respons, dan sikap pengguna terhadap suatu peristiwa umumnya disampaikan secara eksplisit dalam bentuk tulisan. Karakteristik ini memungkinkan sentimen publik diidentifikasi secara lebih langsung dibandingkan platform yang didominasi oleh konten visual atau audiovisual, yang sering memerlukan pendekatan analisis multimodal. Salah satu platform media sosial berbasis teks yang banyak dimanfaatkan dalam kajian analisis sentimen adalah X (sebelumnya Twitter). Platform ini memungkinkan pengguna menyampaikan opini secara singkat, spontan, dan *real-time* terhadap berbagai peristiwa sosial dan kebijakan publik. Sifat komunikasi yang ringkas dan terbuka menjadikan data dari platform X sering digunakan untuk menangkap dinamika persepsi publik secara cepat, terutama pada isu-isu yang bersifat aktual dan sensitif. Oleh karena itu, platform berbasis teks seperti X dinilai relevan untuk merepresentasikan respons emosional dan opini masyarakat dalam konteks analisis sentimen.

Dalam konteks kebencanaan, analisis sentimen memiliki peran strategis karena bencana alam sering kali memicu respons emosional yang kuat dari masyarakat. Indonesia merupakan negara yang rentan terhadap berbagai jenis bencana alam, salah satunya adalah banjir. Banjir tercatat sebagai bencana yang paling sering terjadi, yaitu sebanyak 1.420 kejadian berdasarkan data BNPB tahun 2024, dan secara rutin melanda berbagai wilayah di Indonesia, termasuk di Pulau Sumatra. Wilayah Sumatra memiliki karakteristik geografis dan iklim yang mendukung terjadinya banjir, seperti curah hujan yang tinggi, keberadaan daerah aliran sungai yang luas, serta perubahan tata guna lahan akibat aktivitas manusia (BNPB 2025).

Kejadian banjir tidak hanya menimbulkan kerugian material, tetapi juga berdampak pada aspek sosial, ekonomi, dan psikologis masyarakat (Arashi *et al.* 2024).

Penanganan banjir oleh pemerintah pusat maupun daerah sering menjadi sorotan publik dan memunculkan beragam opini di media sosial. Sentimen yang berkembang di media sosial dapat mencerminkan tingkat kepuasan, kepercayaan, maupun kritik masyarakat terhadap kinerja pemerintah dan lembaga terkait. Oleh karena itu, analisis sentimen terhadap data media sosial dapat dimanfaatkan sebagai sarana untuk mengevaluasi persepsi publik terhadap upaya penanganan bencana. Selain itu, analisis sentimen juga berpotensi mengungkap isu-isu utama yang menjadi perhatian masyarakat, sehingga dapat dijadikan bahan pertimbangan dalam evaluasi kebijakan dan perumusan strategi penanggulangan bencana yang lebih responsif dan berbasis data.

Secara metodologis, analisis sentimen dapat dilakukan menggunakan berbagai pendekatan, mulai dari metode berbasis leksikon hingga metode berbasis *machine learning* dan *deep learning* (Al-Thubaity *et al.* 2018). Pendekatan berbasis leksikon mengandalkan kamus kata bermuatan sentimen, sementara pendekatan berbasis pembelajaran mesin menggunakan data latih untuk membangun model klasifikasi (Azhar 2018). Seiring berkembangnya teknologi komputasi, pendekatan *deep learning* semakin banyak digunakan karena kemampuannya dalam menangkap konteks bahasa yang kompleks, terutama pada data teks yang bersifat sekuensial dan tidak terstruktur.

Salah satu metode *deep learning* yang banyak digunakan dalam analisis sentimen adalah *Long Short-Term Memory* (LSTM), yang merupakan pengembangan dari *Recurrent Neural Network* (RNN) (Cen *et al.* 2020). LSTM dirancang untuk mengatasi permasalahan *vanishing gradient* pada RNN dengan memperkenalkan mekanisme *gate* yang memungkinkan model mempertahankan dan mengelola informasi dalam jangka panjang (Murthy *et al.* 2020). Kemampuan tersebut menjadikan LSTM efektif dalam memodelkan data teks berurutan dan sering digunakan sebagai model *baseline* dalam berbagai penelitian analisis sentimen (Yadav dan Vishwakarma 2020). Meskipun bukan merupakan metode terbaru, LSTM tetap relevan sebagai pembanding dalam evaluasi kinerja metode analisis sentimen berbasis *deep learning*.

Perkembangan NLP selanjutnya ditandai dengan munculnya model berbasis Transformer, yang menunjukkan peningkatan kinerja signifikan dalam berbagai tugas pemrosesan bahasa. Model Transformer memiliki keunggulan dalam menangkap konteks global suatu teks melalui mekanisme *self-attention*, sehingga mampu memahami hubungan antar kata secara lebih baik dibandingkan model sekuensial tradisional. Salah satu model Transformer yang banyak digunakan adalah *Bidirectional Encoder Representations from Transformers* (BERT), yang kemudian diadaptasi ke berbagai bahasa, termasuk bahasa Indonesia. IndoBERTweet merupakan salah satu varian BERT yang dilatih menggunakan data dari platform X berbahasa Indonesia, sehingga lebih sesuai untuk menganalisis teks media sosial yang bersifat informal, mengandung singkatan, serta ekspresi emosional yang kuat (Koto *et al.* 2020).

Seiring berkembangnya model Transformer, proses *fine-tuning* menjadi tahapan penting untuk menyesuaikan model prelatih dengan konteks data spesifik. Pendekatan *fine-tuning* penuh memungkinkan seluruh parameter model diperbarui, namun metode ini membutuhkan sumber daya komputasi yang besar dan berisiko

menyebabkan *overfitting*, terutama pada data dengan ukuran terbatas atau distribusi kelas yang tidak seimbang. Beberapa pendekatan lain seperti *adapter-based tuning* dan *prompt-based tuning* juga telah dikembangkan untuk meningkatkan efisiensi pelatihan, namun masing-masing memiliki keterbatasan dalam fleksibilitas dan stabilitas model pada data nyata. Untuk mengatasi permasalahan tersebut, pendekatan *Low-Rank Adaptation* (LoRA) diperkenalkan sebagai metode *parameter-efficient fine-tuning* yang memungkinkan penyesuaian model Transformer dengan menambahkan parameter ber-*rank* rendah tanpa memperbarui seluruh parameter model. Pendekatan ini terbukti mampu meningkatkan efisiensi pelatihan model dengan tetap mempertahankan kinerja yang kompetitif (Hu *et al.* 2022). Oleh karena itu, kombinasi IndoBERTweet dengan LoRA menjadi pendekatan yang potensial dalam analisis sentimen berbahasa Indonesia.

Beberapa penelitian terdahulu telah membahas kinerja metode LSTM dan BERT. Penelitian oleh Wang dan Jaber (2025) menunjukkan bahwa BERT menghasilkan nilai *F1-score* dan *recall* yang lebih tinggi dibandingkan LSTM pada data ulasan dengan distribusi kelas tidak seimbang, khususnya pada kelas minoritas. Penelitian lain oleh Senjaya dan Sibaroni (2025) mengkaji analisis sentimen publik terhadap kinerja pemerintah dalam penanganan banjir di wilayah Jabodetabek menggunakan model IndoBERT dan model hibrida IndoBERT–CNN–LSTM, hasil penelitian menunjukkan bahwa model IndoBERT memperoleh akurasi sebesar 91,76% dan *F1-score* sebesar 90,66%, sedangkan model IndoBERT + CNN–LSTM menunjukkan kinerja yang lebih baik dengan akurasi sebesar 94,92% dan *F1-score* sebesar 95,41%, sehingga kombinasi IndoBERT dengan CNN–LSTM mampu meningkatkan kinerja klasifikasi sentimen secara signifikan dibandingkan penggunaan IndoBERT tunggal, dengan nilai akurasi dan *F1-score* yang lebih tinggi.

Selain pemilihan metode, tantangan lain dalam analisis sentimen adalah ketidakseimbangan data. Data sentimen yang diperoleh dari media sosial sering kali memiliki distribusi kelas yang tidak merata, di mana satu kelas sentimen mendominasi kelas lainnya. Kondisi data tidak seimbang dapat menyebabkan model klasifikasi cenderung bias terhadap kelas mayoritas dan menurunkan kemampuan model dalam mengenali kelas minoritas, sehingga menghasilkan evaluasi kinerja yang kurang akurat (Johnson dan Khoshgoftaar 2019). Penelitian oleh Filali *et al.* (2024) menunjukkan bahwa ketidakseimbangan kelas merupakan tantangan utama dalam klasifikasi teks karena kelas minoritas cenderung terwakili secara sangat terbatas dibandingkan kelas mayoritas. Hasil penelitian menunjukkan bahwa penggunaan *embedding* BERT yang dikombinasikan dengan *Generative Adversarial Networks* (GANs) mampu meningkatkan representasi kelas minoritas pada dataset teks yang tidak seimbang. Pendekatan ini menghasilkan kinerja klasifikasi yang lebih baik dibandingkan metode konvensional, khususnya dalam meningkatkan kemampuan model untuk mendeteksi data pada kelas minoritas.

Dalam konteks penanganan banjir di wilayah Sumatra, data sentimen publik yang diperoleh dari media sosial cenderung memiliki distribusi kelas yang tidak seimbang akibat dominasi emosi tertentu, terutama sentimen negatif pada saat terjadi bencana. Meskipun berbagai penelitian telah menerapkan model LSTM maupun model berbasis Transformer seperti IndoBERT dalam analisis sentimen, penelitian yang secara khusus membandingkan kinerja LSTM dan IndoBERTweet-

LoRA pada data sentimen tidak seimbang, khususnya dalam konteks penanganan banjir di wilayah Sumatra, masih relatif terbatas.

Berdasarkan uraian tersebut, penelitian ini berfokus pada evaluasi kinerja metode LSTM dan IndoBERTweet berbasis LoRA dalam analisis sentimen publik terhadap penanganan banjir di wilayah Sumatra pada data tidak seimbang. Selain itu, penelitian ini juga diarahkan untuk menganalisis karakteristik sentimen serta mengidentifikasi isu dan topik dominan yang muncul dalam opini publik terkait penanganan banjir di wilayah Sumatra. Dengan demikian, penelitian ini diharapkan dapat memberikan kontribusi baik secara metodologis dalam pengembangan analisis sentimen berbahasa Indonesia maupun secara substantif dalam kajian kebencanaan dan kebijakan publik.

1.2 Rumusan Masalah

Berdasarkan permasalahan di atas, adapun rumusan masalah yang akan dikaji dalam penelitian ini adalah sebagai berikut:

1. Bagaimana kinerja model LSTM dan IndoBERTweet-LoRA dalam analisis sentimen publik terhadap penanganan banjir di wilayah Sumatra pada data tidak seimbang?
2. Bagaimana karakteristik sentimen dan isu utama yang muncul dalam opini publik terkait penanganan banjir di wilayah Sumatra?

1.3 Tujuan

Tujuan dari penelitian ini adalah sebagai berikut:

1. Mengevaluasi kinerja model LSTM dan IndoBERTweet-LoRA dalam mengklasifikasikan sentimen publik terhadap penanganan banjir di wilayah Sumatra pada data tidak seimbang.
2. Menganalisis karakteristik sentimen serta isu dan topik dominan dalam opini publik terkait penanganan banjir di wilayah Sumatra.

1.4 Manfaat


Adapun manfaat dari penelitian ini yakni sebagai berikut:

1. Manfaat Akademis dan Peneliti
 Penelitian ini diharapkan dapat memberikan kontribusi keilmuan dalam bidang analisis sentimen dan pemrosesan bahasa alami (NLP), khususnya terkait evaluasi kinerja model LSTM dan IndoBERTweet-LoRA pada data tidak seimbang, serta menjadi referensi bagi penelitian selanjutnya dengan topik serupa.
2. Manfaat bagi Praktisi
 Hasil penelitian ini diharapkan dapat memberikan informasi dan rekomendasi bagi praktisi, pemerintah, maupun instansi terkait dalam memahami sentimen serta isu utama opini publik terhadap penanganan banjir di wilayah Sumatra, sehingga dapat dimanfaatkan sebagai bahan evaluasi dan perumusan kebijakan yang lebih responsif dan berbasis data.

II TINJAUAN PUSTAKA

2.1 Analisis Sentimen

Menurut Artanti (2018), analisis sentimen atau *opinion mining* merupakan proses untuk mengidentifikasi dan mengekstraksi pendapat pengguna terhadap suatu topik atau teks yang disampaikan. Analisis sentimen bertujuan untuk menentukan polaritas suatu teks, apakah bersifat positif, negatif, atau netral. Analisis sentimen disebut sebagai *opinion mining* karena metode ini berfokus pada penggalian opini atau pendapat yang bersifat subjektif, baik positif, negatif, maupun netral (Samsir *et al.* 2021). Ilustrasi alur sistem dalam melakukan analisis sentimen disajikan pada Gambar 1, yang merupakan tahapan utama dalam proses analisis sentimen.



Gambar 1. Sistem Analisis Sentimen (Purnamasari *et al.* 2023)

Berdasarkan Gambar 1, sistem analisis sentimen terdiri dari beberapa tahapan utama. Tahap pertama adalah *data collection*, yaitu proses pengumpulan data teks yang berasal dari berbagai sumber, seperti media sosial, ulasan daring, atau dokumen teks lainnya. Selanjutnya, dilakukan *data preparation* yang mencakup pembersihan data, normalisasi teks, serta penghapusan elemen yang tidak relevan agar data siap untuk dianalisis. Tahap berikutnya adalah *feature extraction*, yaitu proses mengubah data teks menjadi representasi numerik yang dapat diproses oleh model komputasi. Representasi ini digunakan pada tahap *sentiment classification* untuk mengklasifikasikan sentimen teks ke dalam kategori tertentu, seperti positif, negatif, atau netral. Tahap terakhir adalah *result interpretation*, yaitu proses penafsiran hasil klasifikasi sentimen guna memperoleh informasi dan kesimpulan yang relevan sesuai dengan tujuan analisis (Sangeetha dan Kumaran 2022).

2.2 Natural Language Processing (NLP)


Natural Language Processing (NLP) atau pemrosesan bahasa alami merupakan cabang dari kecerdasan buatan yang berfokus pada analisis, pemahaman, dan pengolahan bahasa alami agar dapat dipahami oleh komputer dengan cara yang menyerupai manusia. NLP memungkinkan sistem komputasi untuk memproses bahasa yang digunakan manusia, baik dalam bentuk teks maupun

ucapan, sehingga mesin dapat mengekstraksi informasi dan pengetahuan dari data bahasa alami (Wadud *et al.* 2022).

NLP memiliki peran penting dalam menjembatani interaksi antara manusia dan komputer melalui bahasa alami. Salah satu tujuan utama NLP adalah memperoleh kecerdasan dari data tidak terstruktur yang diekspresikan dalam bahasa manusia, seperti bahasa Indonesia, yang memiliki karakteristik linguistik tersendiri dari sisi tata bahasa, sintaksis, dan struktur kalimat. Melalui teknik NLP, komputer dapat melakukan berbagai tugas seperti memahami teks, menafsirkan makna, mengukur sentimen, serta menambang opini yang terkandung dalam data tekstual (Sarker *et al.* 2021).


2.3 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) merupakan arsitektur jaringan saraf tiruan yang digunakan untuk memodelkan data berurutan atau sekuens. LSTM diperkenalkan oleh Hochreiter dan Schmidhuber (1997) sebagai metode *deep learning* yang mampu menyimpan dan memanfaatkan informasi dalam jangka panjang. Kemampuan tersebut diperoleh melalui mekanisme memori internal yang memungkinkan model mempertahankan informasi penting serta mengurangi kehilangan informasi selama proses pembelajaran (Murthy *et al.* 2020). Sebagai model yang dirancang untuk menangani data sekuens, LSTM memiliki keterkaitan erat dengan *Recurrent Neural Network* (RNN). Secara arsitektur, LSTM merupakan pengembangan dari RNN yang bertujuan untuk memperbaiki keterbatasan RNN konvensional dalam mempelajari ketergantungan jangka panjang pada data berurutan. *Recurrent Neural Network* (RNN) merupakan jaringan saraf dengan struktur siklik yang memproses data secara berurutan, di mana *output* pada suatu waktu dipengaruhi oleh *input* saat ini serta informasi dari waktu sebelumnya. Namun, RNN konvensional memiliki keterbatasan dalam mempelajari ketergantungan jangka panjang akibat permasalahan *vanishing* dan *exploding gradient*, berikut merupakan arsitektur RNN (Cen *et al.* 2020).



Gambar 2. Arsitektur RNN (Olah 2015)

Untuk mengatasi permasalahan tersebut, LSTM mengembangkan arsitektur RNN dengan menambahkan *memory cell* yang dikendalikan oleh beberapa *gate*, yaitu *forget gate*, *input gate*, dan *output gate* (Chung dan Shin 2018). Mekanisme *gate* ini memungkinkan LSTM mengatur aliran informasi yang disimpan, diperbarui, dan dikeluarkan dari memori secara selektif, sehingga model mampu mempertahankan informasi penting dalam jangka waktu yang lebih panjang dibandingkan RNN konvensional. Berikut merupakan tampilan arsitektur LSTM secara umum.



Gambar 3. Arsitektur LSTM (Yu *et al.* 2019)

Pada waktu t , LSTM terlebih dahulu menentukan informasi mana yang perlu dipertahankan atau dihilangkan dari keadaan sel sebelumnya. Proses ini dikendalikan oleh fungsi aktivasi sigmoid σ yang dikenal sebagai *forget gate* (gerbang lupa), dengan masukan x_t (input saat ini) serta h_{t-1} (keluaran lapisan tersembunyi pada waktu sebelumnya). Nilai *output* dari gerbang ini berada pada rentang nol hingga satu, di mana nilai mendekati satu menunjukkan bahwa informasi dari keadaan sebelumnya dipertahankan, sedangkan nilai mendekati nol menunjukkan bahwa informasi tersebut dihilangkan sepenuhnya, ditunjukkan pada persamaan (1) (Zhang *et al.* 2018).

$$f_t = \sigma(W^f x_t + U^f h_{t-1}) \quad (1)$$

Selanjutnya, LSTM menentukan informasi baru yang akan disimpan dalam *cell state* melalui dua tahap utama. Tahap pertama dilakukan oleh *input gate* (gerbang masuk) ditunjukkan pada persamaan (2), berfungsi untuk memilih informasi yang akan diperbarui, sedangkan tahap kedua menghasilkan vektor kandidat baru $\tilde{C}_t$, yang akan ditambahkan ke *cell state*. Mekanisme ini memungkinkan LSTM mengelola aliran informasi secara adaptif sehingga pembaruan keadaan sel dapat dilakukan secara stabil (Zhang *et al.* 2018).

$$i_t = \sigma(W^i x_t + U^i h_{t-1}) \quad (2)$$

$$\tilde{C}_t = \tanh(W^n x_t + U^n h_{t-1}) \quad (3)$$

Selanjutnya, pembaruan *cell state* dilakukan dengan memperbarui keadaan sel sebelumnya C_{t-1} menjadi keadaan sel baru C_t . Proses ini dikendalikan oleh *forget gate* f_t yang berperan dalam menentukan bagian informasi lama yang dipertahankan atau dihapus. Mekanisme ini memungkinkan LSTM mengontrol aliran gradien secara efektif sehingga membantu mengurangi permasalahan

vanishing gradient maupun *exploding gradient* yang umum terjadi pada RNN standar (Zhang *et al.* 2018).

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (4)$$


Tahap akhir pada LSTM adalah proses pembentukan *output*. Pada tahap ini, *output gate* (gerbang keluar) menentukan bagian dari *cell state* yang akan ditampilkan sebagai keluaran. *Cell state* terlebih dahulu dipetakan melalui fungsi aktivasi tanh, kemudian dikalikan dengan keluaran dari *output gate* berbasis sigmoid. Proses ini memastikan bahwa hanya informasi yang relevan yang diteruskan sebagai keluaran pada setiap langkah waktu (Zhang *et al.* 2018).

$$o_t = \sigma(W^o x_t + U^o h_{t-1}) \quad (5)$$

$$h_t = o_t * \tanh(C_t) \quad (6)$$

2.4 BERT dan IndoBERTweet

Bidirectional Encoder Representations from Transformers (BERT) merupakan model representasi bahasa berbasis Transformer yang dikembangkan oleh Devlin *et al.* (2019). BERT dirancang untuk memahami konteks kata dalam teks secara dua arah (*bidirectional*), yaitu dengan mempertimbangkan kata-kata sebelum dan sesudah suatu token secara bersamaan. Pendekatan ini memungkinkan model memperoleh representasi semantik yang lebih kaya dibandingkan model berbasis urutan satu arah. Arsitektur BERT dibangun menggunakan *encoder* pada model Transformer yang mengandalkan mekanisme *self-attention* untuk memodelkan hubungan antar kata dalam suatu kalimat (Devlin *et al.* 2019).



Gambar 4. Arsitektur BERT (Devlin *et al.* 2019)

Gambar 4 memperlihatkan arsitektur BERT yang terdiri dari tahap *pre-training* dan *fine-tuning*. Pada tahap *pre-training*, BERT dilatih menggunakan tugas *Masked Language Modeling* dan *Next Sentence Prediction* untuk mempelajari representasi bahasa yang kontekstual, sehingga setiap token dipahami berdasarkan konteks kata sebelum dan sesudahnya secara bersamaan. Representasi bahasa yang dihasilkan pada tahap ini memungkinkan model memahami hubungan antar kata secara lebih komprehensif. Selanjutnya, pada tahap *fine-tuning*, model BERT yang telah dipelajari disesuaikan untuk tugas tertentu, termasuk analisis sentimen, dengan menambahkan lapisan keluaran sesuai dengan kebutuhan tugas (Devlin *et al.* 2019).

IndoBERT merupakan pengembangan BERT yang dirancang khusus untuk bahasa Indonesia dan menggunakan arsitektur Transformer *encoder* dengan 12 lapisan tersembunyi, dimensi representasi sebesar 768, serta 12 *attention heads*. Model ini dikembangkan melalui proses pelatihan berskala besar dengan jutaan langkah pelatihan, sehingga mampu mempelajari representasi bahasa Indonesia secara kontekstual (Juarto dan Yulianto 2023). IndoBERTweet merupakan varian IndoBERT yang dilatih menggunakan data media sosial berbahasa Indonesia dari platform X. Perbedaan utama IndoBERTweet dibandingkan BERT umum terletak pada data *pre-training* yang lebih sesuai dengan karakteristik bahasa media sosial, seperti penggunaan bahasa informal, singkatan, dan ekspresi emosional. Dengan pelatihan pada data yang relevan tersebut, IndoBERTweet mampu menghasilkan representasi teks yang lebih adaptif untuk analisis sentimen pada data media sosial berbahasa Indonesia (Koto *et al.* 2020).

2.5 Low-Rank Adaptation (LoRA)

Low-Rank Adaptation (LoRA) merupakan metode *parameter-efficient fine-tuning* yang diperkenalkan oleh (Hu *et al.* 2022) untuk mengadaptasi model pelatihan berukuran besar tanpa perlu memperbarui seluruh parameter model. LoRA bekerja dengan menambahkan matriks berperingkat rendah (*low-rank matrices*) pada lapisan tertentu model, sementara parameter asli model dibekukan selama proses pelatihan. Dengan pendekatan ini, jumlah parameter yang dilatih dapat dikurangi secara signifikan tanpa mengorbankan kinerja model secara substansial.

Secara konseptual, LoRA bekerja dengan memodifikasi bobot linear pada *layer* tertentu, khususnya pada komponen *attention*, tanpa mengubah bobot asli model. Jika W_0 merepresentasikan bobot asli model pelatihan, maka pada LoRA bobot tersebut tidak diperbarui secara langsung. Sebagai gantinya, LoRA menambahkan perubahan bobot ΔW yang didekomposisi menjadi dua matriks berperingkat rendah A dan B , sehingga bobot baru dapat dituliskan sebagai berikut (Hu *et al.* 2022).

$$W = W_0 + \Delta W \quad (7)$$


dengan:

$$\Delta W = BA \quad (8)$$

Dengan demikian, persamaan keluaran layer linear pada LoRA dapat dituliskan sebagai:

$$y = W_0x + BA_x \quad (9)$$

Pada persamaan tersebut, W_0 merupakan bobot asli yang dibekukan, sedangkan A dan B merupakan matriks LoRA yang dilatih selama proses *fine-tuning*. *Rank* dari matriks A dan B ditetapkan jauh lebih kecil dibandingkan dimensi W_0 , sehingga jumlah parameter yang diperbarui menjadi jauh lebih sedikit dibandingkan *fine-tuning* penuh (Hu *et al.* 2022).



Gambar 5. Alur Kerja Penyempurnaan LoRA (Hu *et al.* 2022)

Gambar 5 menunjukkan mekanisme LoRA pada proses *fine-tuning* model prelatih. Pada pendekatan ini, bobot asli model W_0 dibekukan dan tidak diperbarui selama pelatihan. Penyesuaian model dilakukan dengan menambahkan dua matriks berperingkat rendah A dan B , sehingga bobot efektif model dinyatakan sebagai $W = W_0 + BA$. Matriks A dan B memiliki *rank* r yang jauh lebih kecil dibandingkan dimensi W_0 , sehingga hanya sejumlah kecil parameter yang dilatih. Mekanisme ini memungkinkan adaptasi model dilakukan secara efisien tanpa mengubah struktur utama model prelatih (Hu *et al.* 2022).

2.6 Data Tidak Seimbang

Data tidak seimbang (*imbalanced data*) merupakan kondisi pada permasalahan klasifikasi ketika distribusi jumlah data antar kelas tidak proporsional, di mana satu kelas memiliki jumlah observasi yang jauh lebih besar dibandingkan kelas lainnya (Li *et al.* 2011). Kondisi ini sering ditemukan pada berbagai permasalahan klasifikasi di dunia nyata karena data yang tersedia tidak selalu terdistribusi secara merata (Johnson dan Khoshgoftaar 2019).

Ketidakseimbangan distribusi kelas dapat memengaruhi proses pembelajaran model klasifikasi. Model cenderung mempelajari pola dari kelas dengan jumlah data yang lebih besar, sementara karakteristik kelas dengan jumlah data yang lebih sedikit kurang terwakili dalam proses pelatihan. Akibatnya, model dapat menghasilkan prediksi yang bias terhadap kelas mayoritas dan memiliki kinerja yang rendah dalam mengenali kelas minoritas (Koziarski 2020).

Selain memengaruhi proses pembelajaran, data tidak seimbang juga berdampak pada evaluasi kinerja model. Nilai akurasi yang tinggi tidak selalu mencerminkan kinerja model yang baik ketika distribusi kelas tidak seimbang, karena prediksi yang benar pada kelas mayoritas dapat mendominasi hasil evaluasi. Oleh karena itu, pada kondisi data tidak seimbang, interpretasi hasil klasifikasi perlu dilakukan dengan mempertimbangkan distribusi kelas dan karakteristik kesalahan prediksi antar kelas (Johnson dan Khoshgoftaar 2019).

2.7 Evaluasi Kinerja Model Klasifikasi

Evaluasi kinerja model klasifikasi merupakan proses untuk menilai kemampuan suatu model dalam mengelompokkan data ke dalam kelas yang sesuai berdasarkan label sebenarnya. Evaluasi dilakukan dengan membandingkan hasil

prediksi model terhadap data sebenarnya, sehingga dapat diketahui tingkat ketepatan dan keandalan model dalam menyelesaikan tugas klasifikasi (Siringoringo 2018). Dalam penelitian klasifikasi, evaluasi kinerja tidak hanya bertujuan untuk mengetahui seberapa banyak prediksi yang benar, tetapi juga untuk memahami pola kesalahan yang dihasilkan model. Oleh karena itu, evaluasi kinerja model klasifikasi perlu dilakukan secara komprehensif dengan menggunakan representasi dan metrik evaluasi yang sesuai dengan karakteristik data yang digunakan (Santosa 2007).

2.7.1 Confusion Matrix

Menurut Jiawei Han (2012) dalam (Said 2016), *confusion matrix* merupakan alat yang digunakan untuk mengevaluasi kinerja suatu *classifier* dalam mengklasifikasikan data ke dalam kelas yang berbeda. *Confusion matrix* disajikan dalam bentuk tabel yang menggambarkan jumlah data uji yang berhasil diklasifikasikan dengan benar maupun yang mengalami kesalahan klasifikasi (Putra dan Wibowo 2020). *Confusion matrix* pada klasifikasi biner dan multikelas masing-masing disajikan pada Tabel 1 dan Tabel 2.

Tabel 1. *Confusion Matrix* Klasifikasi Biner

		Prediksi	
		Positif	Negatif
Aktual	Positif	True Positive (TP)	False Negative (FN)
	Negatif	False Positive (FP)	True Negative (TN)

Tabel 2. *Confusion matrix* Klasifikasi Multikelas

		Prediksi			
		K_1	K_2	...	K_N
Aktual	K_1	$K_{1,1}$	FP	...	$K_{1,N}$
	K_2	FN	TP	...	FN
	...	...	...	...	...
	K_N	$K_{N,1}$	FP	...	$K_{N,N}$

Empat komponen utama dalam *confusion matrix* pada klasifikasi biner meliputi *True Positive*, *False Positive*, *False Negative*, dan *True Negative*. *True Positive* menunjukkan kondisi ketika data yang sebenarnya bernilai positif diprediksi positif oleh model. *False Positive* menunjukkan kondisi ketika model memprediksi positif, namun data tersebut sebenarnya bernilai negatif, yang dikenal sebagai kesalahan tipe I. *False Negative* menunjukkan kondisi ketika model memprediksi negatif, padahal data sebenarnya bernilai positif, yang disebut sebagai kesalahan tipe II. Sementara itu, *True Negative* menunjukkan kondisi ketika data yang sebenarnya bernilai negatif diprediksi negatif oleh model. *Confusion matrix* pada klasifikasi biner memiliki dimensi 2×2 , sedangkan pada klasifikasi multikelas memiliki dimensi $N \times N$, dengan N menyatakan jumlah label kelas yang berbeda, seperti $K_1, K_2, \dots, K_N$ (Markoulidakis *et al.* 2021).

2.7.2 Metrik Evaluasi

Metrik evaluasi merupakan ukuran kuantitatif yang digunakan untuk menilai kinerja model klasifikasi berdasarkan hasil prediksi yang dihasilkan. Beberapa metrik evaluasi yang umum digunakan antara lain *accuracy*, *precision*, *recall*, dan *F1-score* (Powers 2011). Metrik-metrik tersebut dihitung berdasarkan nilai-nilai yang terdapat pada *confusion matrix*.

1. *Accuracy* digunakan untuk mengukur proporsi seluruh prediksi yang benar terhadap total data pengamatan. Rumus perhitungan *accuracy* disajikan pada Persamaan (10).

$$\text{Accuracy} = \frac{TP+TN}{TP+FP+FN+TN} \times 100\% \quad (10)$$

2. *Precision* digunakan untuk mengukur prediksi model pada suatu kelas, yaitu proporsi prediksi benar dari seluruh prediksi pada kelas tersebut. Rumus perhitungan *precision* ditunjukkan pada Persamaan (11).

$$\text{Precision} = \frac{TP}{TP+FP} \times 100\% \quad (11)$$

3. *Recall* atau *sensitivity* digunakan untuk mengukur kemampuan model dalam mengenali seluruh data aktual pada suatu kelas, yaitu proporsi data kelas tersebut yang berhasil diprediksi dengan benar. Rumus perhitungan *recall* atau *sensitivity* disajikan pada Persamaan (12).

$$\text{Recall} = \frac{TP}{TP+FN} \times 100\% \quad (12)$$

4. *F1-score* digunakan untuk menggambarkan keseimbangan antara *precision* dan *recall* melalui rata-rata harmonis dari kedua metrik tersebut. *Accuracy* dapat digunakan sebagai acuan kinerja algoritma apabila jumlah kesalahan *False Positive* dan *False Negative* relatif seimbang. Namun, pada kondisi distribusi kesalahan yang tidak seimbang, *F1-score* lebih tepat digunakan sebagai acuan kinerja model. Rumus perhitungan *F1-score* disajikan pada Persamaan (13).

$$\text{F1 - score} = \frac{2 \times \text{recall} \times \text{precision}}{\text{recall} + \text{precision}} \times 100\% \quad (13)$$

Pada permasalahan klasifikasi multikelas dengan distribusi kelas yang tidak seimbang, evaluasi kinerja model dilakukan menggunakan *F1-score* rata-rata (*macro average*), yaitu rata-rata *F1-score* dari setiap kelas dengan bobot yang sama. Pendekatan ini memungkinkan penilaian kinerja model dilakukan secara adil pada seluruh kelas sentimen. Perhitungan *F1-score macro average* disajikan pada Persamaan (14).

$$\text{macro F1 score} = \frac{\sum_{i=1}^n \text{F1 score}_i}{n} \times 100 \quad (14)$$

III METODE

3.1 Data

Data yang digunakan dalam penelitian ini terdiri atas data empiris dan data simulasi sebagai berikut.

3.1.1 Data Empiris

Data empiris dalam penelitian ini merupakan data yang diperoleh melalui proses *scraping* dari media sosial Twitter (X). Pengambilan data dilakukan menggunakan bahasa pemrograman *Python* versi 3.11.8 dengan bantuan *library Playwright*, yang berfungsi untuk mengotomatisasi interaksi dengan halaman *web* sehingga memungkinkan pengambilan data dari konten publik Twitter (X). Proses *scraping* dijalankan melalui perangkat lunak *Visual Studio Code*. Data yang dikumpulkan berupa *tweet* yang dipublikasikan oleh pengguna Twitter (X) dalam rentang waktu 25 November 2025 hingga 14 Januari 2026, diperoleh data sebanyak 19.785 *tweet*. *Tweet* yang dikumpulkan dibatasi pada *tweet* berbahasa Indonesia dan memiliki keterkaitan dengan peristiwa banjir di wilayah Sumatra. Proses *scraping* dilakukan dengan menerapkan sejumlah parameter dan *query* tertentu, seperti penggunaan kata kunci tematik dan lokasi, penyaringan bahasa, serta penghapusan *tweet* yang mengandung tautan eksternal. Parameter dan nilai yang digunakan dalam proses pengambilan data empiris disajikan pada Tabel 3 berikut.

Tabel 3. Parameter dan Nilai *Scraping* Data

Parameter	Nilai
<i>Keyword</i>	banjir, banjir bandang, banjir besar, serta kata kunci lokasi di wilayah Sumatra
<i>Language</i>	lang:id
<i>Tweet Fields</i>	tweet id, username, created at, text, keyword
<i>Links</i>	-has:links
<i>Start Time</i>	2025-11-25
<i>End Time</i>	2026-01-14

Keterangan:

- Kata banjir, banjir bandang, banjir besar digunakan untuk mengumpulkan *tweet* yang membahas peristiwa banjir.
- Aceh, Padang, Sumatera Barat, Sumatera Utara, Riau, Jambi, Lampung, Sumatera Selatan digunakan untuk membatasi konteks wilayah penelitian di Pulau Sumatra.
- *lang:id* digunakan untuk memastikan *tweet* yang dikumpulkan berbahasa Indonesia.
- *-has:links* digunakan untuk mengecualikan *tweet* yang mengandung tautan eksternal.

Data empiris yang diperoleh selanjutnya digunakan sebagai data utama dalam analisis sentimen publik terhadap penanganan banjir di wilayah Sumatra dengan kondisi distribusi kelas yang tidak seimbang.

3.1.2 Data Simulasi

Data simulasi dalam penelitian ini dibentuk berdasarkan data empiris yang telah melalui tahap pelabelan sentimen. Data simulasi tidak dibangkitkan dalam bentuk teks baru, melainkan diperoleh dengan menyusun ulang data empiris untuk merepresentasikan variasi tingkat ketidakseimbangan kelas sentimen secara terkontrol. Pembentukan data simulasi dilakukan dengan mengatur proporsi jumlah data pada setiap kelas sentimen menggunakan teknik pengambilan sampel acak tanpa pengembalian. Proses ini bertujuan untuk menghasilkan beberapa skenario distribusi kelas sentimen yang berbeda tanpa mengubah isi teks *tweet*, sehingga karakteristik bahasa, konteks sosial, serta pola sentimen pada data tetap terjaga. Data simulasi digunakan sebagai data pendukung untuk mengevaluasi konsistensi kinerja model pada berbagai tingkat ketidakseimbangan kelas, tanpa menggantikan peran data empiris sebagai data utama penelitian.

3.2 Prosedur Analisis Data

Prosedur analisis data dalam penelitian ini dirancang untuk mengevaluasi kinerja model LSTM dan IndoBERTweet-LoRA dalam analisis sentimen publik terhadap penanganan banjir di wilayah Sumatra pada kondisi data tidak seimbang. Analisis dilakukan terhadap data empiris dan data simulasi dengan alur pemodelan yang konsisten agar hasil yang diperoleh dapat dibandingkan secara objektif. Seluruh proses pengolahan dan analisis data dilakukan menggunakan bahasa pemrograman *Python*.

A. Kajian pada data empiris

1. Akuisisi data empiris dilakukan melalui proses *scraping* dari media sosial X. Data yang dikumpulkan berupa *tweet* publik berbahasa Indonesia yang berkaitan dengan peristiwa dan penanganan banjir di wilayah Sumatra sesuai dengan periode pengamatan yang telah ditetapkan.
2. Melakukan seleksi dan pembersihan data dengan menghapus *tweet* duplikat, *tweet* yang tidak relevan dengan konteks banjir di Sumatra, *tweet* yang bersifat informatif tanpa opini karena tidak mencerminkan sentimen pengguna, serta *tweet* yang berasal dari akun otomatis atau respons berbasis kecerdasan buatan.
3. Melakukan pelabelan sentimen secara manual oleh peneliti ke dalam tiga kelas sentimen, yaitu negatif, netral, dan positif, berdasarkan pedoman pelabelan yang telah ditetapkan. *Tweet* dengan makna ambigu diperiksa kembali untuk menjaga konsistensi label.
4. Menganalisis distribusi kelas sentimen pada data empiris untuk mengidentifikasi kondisi ketidakseimbangan kelas yang terjadi secara alami.
5. Melakukan eksplorasi awal data teks menggunakan visualisasi *wordcloud* untuk melihat kata-kata yang sering muncul pada keseluruhan data dan pada masing-masing kelas sentimen guna memperoleh gambaran umum karakteristik teks.
6. Data teks yang telah dilabeli selanjutnya melalui tahap pra-pemrosesan sebelum pemodelan. Tahapan pra-pemrosesan meliputi *case folding* untuk

mengubah seluruh huruf menjadi huruf kecil, *filtering* untuk menghapus tanda baca, angka, URL, mention, simbol *hashtag*, dan karakter tidak relevan dengan tetap mempertahankan *emoticon* untuk merepresentasikan ekspresi emosional pengguna yang dapat memperkuat informasi sentimen dalam teks, normalisasi kata tidak baku ke bentuk baku bahasa Indonesia, *stopword removal* untuk menghapus kata umum yang tidak bermakna sentimen, *stemming* untuk mengembalikan kata ke bentuk dasarnya, serta tokenisasi untuk memecah teks menjadi unit kata.

7. Data empiris dibagi menjadi data latih dan data uji dengan proporsi 80% untuk data latih dan 20% untuk data uji.
8. Merepresentasikan teks hasil pra-pemrosesan dilakukan dalam bentuk numerik. Pada model LSTM digunakan *embedding layer*, sedangkan pada model IndoBERTweet-LoRA digunakan *tokenizer* dan *embedding* pralatih sesuai arsitektur model.
9. Model LSTM dilatih menggunakan data latih dengan konfigurasi *hyperparameter* yang ditetapkan secara tetap. Model IndoBERTweet dilatih menggunakan pendekatan *fine-tuning* berbasis LoRA dengan menambahkan parameter ber-rank rendah pada lapisan tertentu, tanpa dilakukan penyetelan *hyperparameter* lanjutan.
10. Model LSTM dan IndoBERTweet-LoRA yang telah dilatih digunakan untuk menghasilkan prediksi sentimen pada data uji.


B. Kajian pada data simulasi

1. Data simulasi dibentuk dari data latih hasil pembagian data empiris yang telah diberi label sentimen dengan cara mengatur ulang proporsi jumlah data pada setiap kelas sentimen.
2. Pembentukan data simulasi menggunakan teknik pengambilan sampel acak tanpa pengembalian pada masing-masing kelas sentimen pada data latih.
3. Data simulasi disusun ke dalam tiga skenario distribusi kelas sentimen, yaitu skenario seimbang dengan rasio kelas negatif, netral, dan positif sebesar 1:1:1 sebagai pembandingan awal untuk mengevaluasi perilaku dasar model pada kondisi distribusi kelas seimbang, skenario tidak seimbang sedang dengan rasio 6:3:1, serta skenario tidak seimbang tinggi dengan rasio 8:1:1 yang digunakan untuk menguji ketahanan model terhadap dominasi kelas mayoritas.
4. Representasi teks pada data simulasi dilakukan dengan pendekatan *embedding layer* pada model LSTM serta *tokenizer* dan *embedding* pralatih pada model IndoBERTweet-LoRA.
5. Model LSTM dan IndoBERTweet-LoRA dilatih pada setiap skenario data simulasi menggunakan konfigurasi *hyperparameter* yang ditetapkan secara tetap tanpa menerapkan teknik penanganan data tidak seimbang.
6. Model yang telah dilatih digunakan untuk menghasilkan prediksi sentimen pada data uji untuk masing-masing skenario data simulasi.

C. Evaluasi kinerja model

1. Mengevaluasi kinerja model LSTM dan IndoBERTweet-LoRA menggunakan data uji pada data empiris dan setiap skenario data simulasi.

2. Menghitung metrik evaluasi yang sesuai untuk data tidak seimbang, meliputi *precision*, *recall*, dan *F1-score* pada masing-masing kelas sentimen, serta nilai *F1-score* rata-rata (*macro average*) sebagai metrik evaluasi utama.
3. Menganalisis hasil evaluasi kinerja masing-masing model berdasarkan nilai metrik evaluasi yang diperoleh pada data empiris.
4. Menganalisis kinerja model LSTM dan IndoBERTweet-LoRA pada setiap skenario data simulasi dengan rasio 1:1:1, 6:3:1, dan 8:1:1 untuk mengkaji pengaruh tingkat ketidakseimbangan kelas terhadap performa model.
5. Mengamati perubahan nilai metrik evaluasi antar skenario distribusi kelas sebagai dasar penilaian kestabilan kinerja model terhadap variasi tingkat ketidakseimbangan data.



Gambar 6. Diagram Alir Penelitian

DAFTAR PUSTAKA

- Al-Thubaity A, Alqahtani Q, Aljandal A. 2018. Sentiment lexicon for sentiment analysis of Saudi dialect tweets. Di dalam: *Procedia Computer Science*. Vol. 142.
- Arashi FB, Lestari Iskandar A, Sarifah F, Azril M, Ramadhan R, Daniswara MP, Rahmadhani F. 2024. Analisis Dampak Bencana Banjir terhadap Kondisi Sosial dan Ekonomi pada Masyarakat. *Bandar: Journal of Civil Engineering*. 6(2).
- Artanti DPM. 2018. Syukur A Prihandono A and Setiadi DRIM, 2018 Analisa Sentimen Untuk Penilaian Pelayanan Situs Belanja Online Menggunakan Algoritma Naive Bayes *Nas. Sist. Inf.*
- Azhar Y. 2018. METODE LEXICON-LEARNING BASED UNTUK IDENTIFIKASI TWEET OPINI BERBAHASA INDONESIA. *Jurnal Nasional Pendidikan Teknik Informatika (JANAPATI)*. 6(3).doi:10.23887/janapati.v6i3.11739.
- BNPB. 2025. *Data Bencana Tahun 2024*. Volume ke-3.
- Cen P, Zhang K, Zheng D. 2020. Sentiment Analysis Using Deep Learning Approach. *Journal on Artificial Intelligence*. 2(1).doi:10.32604/jai.2020.010132.
- Chung H, Shin KS. 2018. Genetic algorithm-optimized long short-term memory network for stock market prediction. *Sustainability (Switzerland)*. 10(10).doi:10.3390/su10103765.
- Devlin J, Chang MW, Lee K, Toutanova K. 2019. BERT: Pre-training of deep bidirectional transformers for language understanding. Di dalam: *NAACL HLT 2019 - 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies - Proceedings of the Conference*. Vol. 1.
- Filali A, Abdellaoui Alaoui EA, Merras M. 2024. Enhancing spam detection with GANs and BERT embeddings: A novel approach to imbalanced datasets. Di dalam: *Procedia Computer Science*. Vol. 236.
- Hu E, Shen Y, Wallis P, Allen-Zhu Z, Li Y, Wang S, Wang L, Chen W. 2022. LORA: LOW-RANK ADAPTATION OF LARGE LANGUAGE MODELS. Di dalam: *ICLR 2022 - 10th International Conference on Learning Representations*.
- Jiawei Han MK and JP. 2012. Data Mining: Concepts and Techniques, Third Edition - Books24x7. *Morgan Kaufmann Publishers*.
- Johnson JM, Khoshgoftaar TM. 2019. Survey on deep learning with class imbalance. *J. Big Data*. 6(1).doi:10.1186/s40537-019-0192-5.
- Juarto B, Yulianto. 2023. Indonesian News Classification Using IndoBert. *International Journal of Intelligent Systems and Applications in Engineering*. 11(2).
- Koto F, Rahimi A, Lau JH, Baldwin T. 2020. IndoLEM and IndoBERT: A Benchmark Dataset and Pre-trained Language Model for Indonesian NLP. Di dalam: *COLING 2020 - 28th International Conference on Computational Linguistics, Proceedings of the Conference*.
- Koziarski M. 2020. Radial-Based Undersampling for imbalanced data classification. *Pattern Recognit*. 102.doi:10.1016/j.patcog.2020.107262.
- Li S, Zhou G, Wang Z, Lee SYM, Wang R. 2011. Imbalanced sentiment classification. Di dalam: *International Conference on Information and Knowledge Management, Proceedings*.

Markoulidakis I, Rallis I, Georgoulas I, Kopsiaftis G, Doulamis A, Doulamis N. 2021. Multiclass Confusion Matrix Reduction Method and Its Application on Net Promoter Score Classification Problem. *Technologies (Basel)*. 9(4).doi:10.3390/technologies9040081.

Murthy GSN, Allu SR, Andhavarapu B, Bgadi M, Belusonti M. 2020. Text based Sentiment Analysis using Long Short Term Memory (LSTM). *International Journal of Engineering Research & Technology (IJERT)*. 9(05).

Olah C. 2015. Understanding LSTM Networks [Blog]. *Web Page*.

Powers DMW. 2011. Estimation of high affinity estradiol binding sites in human breast cancer EVALUATION: FROM PRECISION, RECALL AND F-MEASURE TO ROC, INFORMEDNESS, MARKEDNESS & CORRELATION. *Journal of Machine Learning Technologies*. 2(1).

Prakash TN, Aloysius A. 2021. Textual Sentiment Analysis using Lexicon Based Approaches. *Ann. Rom. Soc. Cell Biol*. 25(4).

Purnamasari D, Aji AB, Wulandari D, Reza FA, Safrila M, Yanda N, Hidayati U. 2023. *Pengantar Metode Analisis Sentimen*.

Putra D, Wibowo A. 2020. Prediksi Keputusan Minat Penjurusan Siswa SMA Yadika 5 Menggunakan Algoritma Naïve Bayes. *Prosiding Seminar Nasional Riset Dan Information Science (SENARIS)*. 2.

Said B. 2016. Klasifikasi Dan Analisis Sentimen Data Sms Center Bupati Pamekasan Menggunakan Naïve Bayes Dengan Mad Smoothing. *Jurnal Link*.

Samsir S, Ambiyar A, Verawardina U, Edi F, Watrianthos R. 2021. Analisis Sentimen Pembelajaran Daring Pada Twitter di Masa Pandemi COVID-19 Menggunakan Metode Naïve Bayes. *JURNAL MEDIA INFORMATIKA BUDIDARMA*. 5(1).doi:10.30865/mib.v5i1.2580.

Sangeetha J, Kumaran U. 2022. Comparison of sentiment analysis on online product reviews using optimised RNN-LSTM with support vector machine. *Webology*. 19(1).

Santosa B. 2007. Data Mining Teknik Pemanfaatan Data untuk Keperluan Bisnis. *Graha Ilmu*. 52.

Sarker IH, Hoque MM, Uddin MK, Alsanoosy T. 2021. Mobile Data Science and Intelligent Apps: Concepts, AI-Based Modeling and Research Directions. *Mobile Networks and Applications*. 26(1).doi:10.1007/s11036-020-01650-z.

Senjaya AM, Sibaroni Y. 2025. Geospatial Sentiment Analysis of Twitter User (X) on Government Performance in Overcoming Floods in Jabodetabek Using IndoBERT and CNN-LSTM Methods. *Jurnal Pendidikan dan Teknologi Indonesia*. 5(11):3386–3398.doi:10.52436/1.jpti.1182.

Siringoringo R. 2018. Klasifikasi Data Tidak Seimbang Menggunakan Algoritma SMOTE Dan K-Nearest Neighbor. *Jurnal ISD*. 3(1).

Wadud MAH, Mridha MF, Rahman MM. 2022. Word Embedding Methods for Word Representation in Deep Learning for Natural Language Processing. *Iraqi Journal of Science*. 63(3).doi:10.24996/ijs.2022.63.3.37.

Wang G, Jaber MM. 2025. A Deep Learning Approach to Sentiment Analysis of Hotel Reviews: Comparing BERT and LSTM Models. *International Journal of Advances in Artificial Intelligence and Machine Learning*. 2(2).doi:10.58723/ijaaiml.v2i2.403.

Yadav A, Vishwakarma DK. 2020. Sentiment analysis using deep learning architectures: a review. *Artif. Intell. Rev*. 53(6).doi:10.1007/s10462-019-09794-5.

Yu Y, Si X, Hu C, Zhang J. 2019. A review of recurrent neural networks: Lstm cells and network architectures. *Neural Comput.* 31(7).doi:10.1162/neco_a_01199.

Zhang L, Wang S, Liu B. 2018. Deep learning for sentiment analysis: A survey. *Wiley Interdiscip. Rev. Data Min. Knowl. Discov.* 8(4).doi:10.1002/widm.1253.